

协同过滤推荐算法研究进展

翁小兰^{1,2}, 王志坚¹

WENG Xiaolan^{1,2}, WANG Zhijian¹

1. 河海大学 计算机与信息学院, 南京 211100

2. 淮阴师范学院 计算机科学与技术学院, 江苏 淮安 223300

1. College of Computer & Information Engineering, Hohai University, Nanjing 211100, China

2. School of Computer Science & Technology, Huaiyin Normal University, Huai'an, Jiangsu 223300, China

WENG Xiaolan, WANG Zhijian. Research process of collaborative filtering recommendation algorithm. Computer Engineering and Applications, 2018, 54(1): 25-31.

Abstract: Recommended technology is widely applied in various fields, and the successful application of the collaborative filtering recommendation algorithm is especially significant. This paper mainly introduces the basic concept and principle of the collaborative filtering recommendation algorithm, including such aspects: algorithm work flow, recommends process as well as the experiment assessment. The collaborative filtering technique faces up to some problem, although it has achieved great success, because of its algorithm features. The paper analyzes these problems and proposes the corresponding solution of collaborative filtering recommendation algorithm, and finally puts forward the new research hotspots of the collaborative filtering recommendation algorithm.

Key words: collaborative filtering; cold-start; sparsity; scalability

摘 要: 推荐技术在各个领域得到了广泛的应用, 其中协同过滤推荐算法显得尤为突出。从基本概念、工作流程以及评估指标等方面介绍了传统的协同过滤推荐算法, 对此类算法存在的数据稀疏性、冷启动、扩展性问题进行了分析, 并分类详细归纳了这些问题的研究现状和解决方案; 最后提出了协同过滤推荐算法在融合大数据技术、社会网络分析技术以及关键用户分析技术三方面的研究热点。

关键词: 协同过滤; 冷启动; 稀疏性; 扩展性

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.1710-0081

1 引言

人们生活在一个信息技术日新月异、移动互联网和云计算迅猛发展、全球数据量呈爆炸式增长的时代。它在为人类提供丰富信息资源的同时, 也将人类带入了严重的“信息过载”^[1]境地。用户往往在海量数据面前无从选择自身感兴趣或有用的信息, 比如: 电子商务网站中选购商品, 新闻资讯网站中选择感兴趣的新闻, 视频点播网站选择适当的影片等等。推荐系统应运而生, 它在信息过滤、信息细化以及向用户提供个性化服务中发挥了显著作用, 提供了一种崭新的信息服务模式。

迄今为止, 实际商业网站运行的推荐系统中主要包括三种算法: 基于内容过滤、协同过滤以及混合推荐算法。协同过滤算法(Collaborative Filtering, CF)具有处理非结构化数据(如: 影片、音乐等)的优点, 因而得到学术界和工业界的广泛关注和研究。国内外大量知名网站使用 CF 算法提供推荐服务, 如: Netflix.com、Amazon.com.Last.fm 等等^[2]。

协同过滤推荐算法虽然得到了广泛的应用, 但面临着评价数据稀疏、冷启动以及扩展性等问题, 为了解决以上问题, 国内外科研人员提出了各种改进方法和解决思路。

基金项目: 国家自然科学基金青年基金(No.11201168)。

作者简介: 翁小兰(1977—), 女, 博士生, 副教授, 研究领域为推荐算法、数据挖掘, E-mail: wxl@hytc.edu.cn; 王志坚(1958—), 男, 博士, 教授, 研究领域为数据挖掘、软件重用技术。

收稿日期: 2017-10-12 **修回日期:** 2017-12-01 **文章编号:** 1002-8331(2018)01-0025-07

2 协同过滤推荐算法

2.1 算法基本概念

CF 算法最早由 Goldberg 等人在 1992 年提出,并应用于电子邮件推荐系统 Tapestry 中,标志着推荐系统的诞生。它通过查找与目标用户评分相似的用户,然后把他们感兴趣的项目推荐给目标用户,称为基于用户的协同过滤推荐算法(User-based CF)。该方法的推荐结果反映了用户所在兴趣小群体中项目的热门程度,适用于像网络新闻、网络文献分享、微博等物品数量大且更新频繁的场所。

在实际应用中(如电子商务、视频点播),用户数量远远大于项目数量,而且项目的相似度相对于用户的兴趣较稳定,由此亚马逊在 2001 年提出了基于项目的协同过滤推荐算法(Item-based CF)。它计算项目在评分数据上的相似程度,然后给目标用户推荐那些和他之前偏好类似的项目。该方法的推荐结果更加个性化,适用于用户兴趣比较固定和持久的场合,在亚马逊、豆瓣和 Netflix 中发挥了极大的优势^[3]。

User-based CF 和 Item-based CF 算法都是基于内存的协同过滤推荐算法(Memory-based),另外一类是基于模型的协同过滤推荐算法(Model-based)。Model-based CF 算法采用贝叶斯网络、聚类、关联规则挖掘等机器学习或数据挖掘方法,对评分数据样本进行训练学习并建立推荐模型,此类算法具有较高的准确度和执行效率,但需要花费代价训练模型,推荐结果的好坏过分地依赖模型。

2.2 算法工作流程

推荐系统是一种帮助用户快速发现有用信息的智能工具,它通过分析用户的历史行为,主动给用户满足其需求和兴趣的商品、新闻等。整个推荐算法工作的流程中,用户无需提供任何明确需求,系统完全根据用户的过去行为预测未来可能感兴趣的内容。

基于内存的协同过滤方法也被称为基于邻域的协同过滤方法,具有直观、易实现、无需长时间的训练过程,得到了充分的应用和发展。它们的运作核心无非包括以下三个步骤^[4]:

(1)收集用户偏好,用户以多种方式向系统表达其偏好,既可以是直接打分、投票、打标签、评论等显式方式(Explicit Rating),也可以是购买、浏览等隐式形式(Implicit Rating)。

(2)寻找最近邻,寻找目标用户的最近邻居集或者项目的最近邻居集。通过 Jaccard 系数、余弦相似性(或修正的)、Pearson 相关性等度量用户或项目之间的相似度,寻找历史评分上的最近邻居。

(3)预测评分:根据最近邻居集计算目标用户对目标项目的预测评分,并在此基础上给出推荐。

2.3 算法性能评测指标

推荐系统的性能是由用户对推荐结果的满意程度决定的,也是衡量其推荐质量好坏的重要指标。在实际应用中,统计精度度量方法和决策支持精度度量方法分别用来评测推荐系统的推荐精度和准确度。

统计精度度量方法中最常用的是平均绝对误差(Mean Absolute Error, MAE)和均方根误差(Root Mean Squared Error, RMSE),MAE 值直观地反映了预测值与真实评分之间的误差, RMSE 值反映了预测评分的精密程度,常作为回归系统的拟合标准差。

决策支持方法主要包括:召回率(Recall)和准确率(Precision)。召回率揭示了待推荐项目被推荐的比例,而准确率揭示了算法成功推荐的比例。

上述评价方法可以通过离线实验进行定量计算,也是几乎 99% 与推荐算法相关的文献都在讨论的指标。其他还有一些方法可以通过用户调查或在线评测来实现,比如:用户满意度、推荐的新颖度和用户对推荐系统的信任度等。

3 协同过滤推荐算法面临的问题

尽管协同过滤技术自被提出以来,得到了推广和应用,也取得了很大的成功,但是由于自身的算法特性以及应用场景不可避免的一些问题,该方法也面临着一系列挑战,主要表现在^[5]:

(1)稀疏性问题(Sparsity)。在没有任何刺激和鼓励评分的优惠措施下,用户自愿给出评价的很少^[6],更不用说不同用户在同一项目上的共同评价了。传统协同过滤推荐算法在评价数据稀疏的情况下,用户间、项目间的相似性计算不准确,导致推荐精度受到极大的影响。

(2)冷启动问题(Cold-start)^[7]。推荐系统需要根据用户的历史评价数据预测用户未来的兴趣,当一个新用户或一个新项目进入系统,亦或是一个全新的系统刚启动,都会面临冷启动问题。

(3)扩展性问题(Scalability)。正常的商业网站都会存在数以万计的用户和项目,推荐算法在最近邻居计算时的搜索时间和空间将会非常庞大。可想而知,在如此巨大的数据量面前,协同过滤推荐方法很难保证算法的实时性。

为了有效解决传统协同推荐算法存在的不足,国内外科研人员进行了深入研究,并提出了各种改进算法。

3.1 稀疏性

解决数据稀疏性的问题,主要有两种思路:其一,基于数据填充的方法,借助其他有用信息建立有效的项目特征模型和用户兴趣模型并以此弥补评价数据的稀疏问题,这类信息可以是项目的内容信息^[8-10]、用户对项目

的标签信息^[11-12]、用户对项目的隐式反馈数据^[13]等等。其二,在原有评分数据的基础上,通过矩阵划分、聚类、矩阵分解等机器学习方法进行评分数据的预处理。

文献[8]首先利用云模型对原始评分数据进行填充,然后综合考虑项目的评分数据和属性特征进行项目相似性计算,并在此基础上预测评分和推荐,实验结果表明,该算法能够解决数据稀疏带来的相似性度量不准确的问题,从而显著提高了算法的推荐精度。文献[9]提出了一种综合用户和项目因素的混合协同过滤推荐(HCFR)算法,该方法适用于评分数据极端稀疏的情况。文献[10]提出了一种基于项目相似度的数据填充方法,其目的在于当原始数据集极度稀疏时通过数据填充为算法提供足够的数据支持。以上三种方法只适用于项目属性特征容易描述和提取的情况,另外,特征提取的标准和方法很难有统一的规范。文献[11]和[12]利用用户产生内容:标签,获取对项目比较准确的描述,从而提高推荐系统的性能,适用于难以提取项目特征的应用场景。

针对评价数据的稀疏性问题,文献[14]基于降低维度的思想,将参与相似度计算的两个用户投影到一个低维空间上,增加评价数据的稠密度,从而提高了协同过滤算法的效率。文献[15]提出了基于Bayesian模型的多准则推荐算法,该方法从多方面建立用户偏好数据,并通过隐主题将用户和项目映射到各自群体,实验证明贝

叶斯模型在多准则评价推荐系统中是有效的,同时可以缓解冷启动问题。文献[16]为了降低数据的稀疏度,对原有评分矩阵进行划分,尽可能缩小近邻搜索的范围和需要预测的资源数目,实验结果表明该方法在算法性能上优于传统协同过滤算法。

在众多解决数据稀疏性问题的方法中,矩阵分解技术可谓是一枝独秀,吸引了大量的研究者,尤其是隐语义模型LFM(Latent Factor Model)几乎成为耳熟能详的技术名词。从最初的基于矩阵奇异值分解的SVD算法^[14,17-18],到通过矩阵分解建立用户和隐类、项目和隐类之间关系的Funk_SVD算法^[19](被Netflix Prize的冠军Koren称为隐语义模型LFM),再到考虑领域影响的SVD++算法^[20],以及后来发展起来的将概率分布函数引入到矩阵分解中的PMF、BPMF算法^[21-22]。矩阵分解技术逐渐成熟,很大程度上解决了协同过滤推荐算法所面临的数据稀疏性问题,如表1列举了几种常见的矩阵分解方法。

研究表明,标签数据、用户之间的信任关系、评价时间体现了用户的历史兴趣以及兴趣的迁移,因此,部分学者在矩阵分解过程中引入了标签数据、信任关系以及时间上下文等信息,以达到提高推荐精度的目的。

3.2 冷启动

目前针对冷启动问题提出了一些解决方法,如随机推荐法(对于新用户,系统从包括新项目在内的所有项

表1 常见的几种矩阵分解方法描述

算法		描述
SVD (奇异值分解)	工作原理	(1)将补齐后的评分矩阵进行奇异值分解 (2)取F个最大的奇异值组成对角矩阵 S_F ,则: $\hat{R} = U_F^T S_F V_F$
	优点缺点	思路简单,但需补齐原评分矩阵中的缺失值,计算复杂度高,存在过度拟合和缺乏精确性
	适用场景	最早应用于IR领域中的LSI技术上,后被Sarwar等人引入到协同过滤推荐算法中,适用于评分数据量不是特别大的场景,否则,算法效率很难保证
funk_SVD (隐语义模型)	工作原理	(1)发现F个隐类,初始化用户特征矩阵 $U \in R^{M \times F}$ 和项目特征矩阵 $V \in R^{F \times N}$ (2)为获得最小的预测误差,定义损失函数: $L(U, V) = \sum_{(i,j) \in \text{train}} (R_{ij} - \sum_{f=1}^F U_{if} V_{jf})^2 + \lambda (\ U_i\ ^2 + \ V_j\ ^2)$ 为了防止学习的过拟合,加入了正则项: $\lambda (\ U_i\ ^2 + \ V_j\ ^2)$
	优点缺点	(3)利用随机梯度下降法最小化损失函数,对特征矩阵进行优化 可以有效处理大数据并能达到比较理想的推荐精度,但没有考虑用户评分偏差,精度有待提高,当数据集非常稀疏时,该算法性能明显下降
	适用场景	在训练过程中只需处理隐含特征向量,无需存储所有用户和项目数据,比较适合海量数据的情况
SVD++	工作原理	在fun_SVD的基础上考虑了系统的整体评分偏差 μ ,用户评分偏差 b_u ,项目评分偏差 b_i ,损失函数为: $L(U, V) = \sum_{(i,j) \in \text{train}} (R_{ij} - \mu - b_i - b_j - \sum_{f=1}^F U_{if} V_{jf})^2 + \lambda (\ U_i\ ^2 + \ V_j\ ^2 + b_i^2 + b_j^2)$
	优点缺点	预测评分时,引入隐式反馈增加预测准确度,尤其适用于显式反馈缺失的情况。但是隐式反馈数据的采集并没有统一的衡量标准,算法的性能受使用场景的限制
	适用场景	隐式反馈数据比较好提取的应用场景,在较低学习率下,该方法有着比funk-SVD更好的推荐精度
PFM BPMF	工作原理	从概率的角度预测用户对项目的评分,是隐语义模型的概率化形式
	优点缺点	能够自动学习模型中的参数,达到更好的模型稳定性和更高的推荐准确率。该算法的前提假设是用户和项目的特征矩阵均满足高斯分布,但当评价数据极度稀疏的情况下,很难保证这一假设
	适用场景	数据的稀疏性会严重影响推荐结果的精度,因此,这两种方法适合评价数据比较稠密的应用环境

目中随机选取进行推荐,然后根据用户的评价反馈,了解新用户的兴趣偏好同时得到接受新项目的用户群体)、平均值法(将项目的评分均值作为目标用户对未评价项目的预测值)、众数法(将用户曾经使用过最多的评价价值作为对未评价项目的预测值)。另一类方法是,在计算相似性时融入用户的人口统计学信息^[23-24]、背景知识(社交网络^[25])、信任关系^[7,26],综合考虑项目的内容信息^[27]以及提出新的相似性度量方法^[28-30]等。不同的算法具有各自的优缺点,具有一定的适用场景。

文献[23]将用户的人口统计信息引入到推荐算法,从而形成混合协同过滤推荐算法,可以很好地解决冷启动问题。文献[24]首先通过人口统计学信息对用户进行聚类,然后在原有评分数据上进行矩阵分解,重新融合成新的评分矩阵,并在此基础上计算用户最近邻和推荐,实验表明,该方法可以解决冷启动和数据稀疏性问题,而且可以提高推荐精确度,但是以上两种方法都需要用到额外的用户属性数据。文献[25]提出了一种融合用户社交信息(包括用户的喜好,所推荐项目的普遍接受状况以及社交朋友的影响等)的推荐系统,通过实验验证,该方法能有效解决冷启动问题。文献[26]在传统的基于用户的协同过滤推荐算法中,融入了项目评分信任度的思想,同时摒弃了传统的相似度计算方法,实验证明,该算法既能缓解数据稀疏性问题并能很好地解决冷启动问题。文献[27]融合了基于内容和协同推荐的方法,利用两者的优点,同时避免了他们的缺点,但只适合内容特征易提取的场合。文献[28]提出了一种新的启发式相似度计算方法来缓解冷启动问题,并着重提高系统的推荐性能。实验结果表明,该方法在解决新用户冷启动问题具有一定的优越性。文献[29]提出了一种新的基于神经网络的相似性度量方法,能够有效地解决新用户冷启动问题。

另外,也有部分学者试图通过机器学习的方法将用户或项目的内容信息融入到用户评分数据中^[31],以达到寻求两者内在联系,并在此基础上产生推荐,最终解决冷启动问题的目的。

3.3 扩展性

协同过滤推荐算法的时间复杂度为 $O(n^2m)$,当推荐系统面临数以百万甚至千万级别的用户和项目时,计算开销非常庞大,算法的实时性将很难保证,相应的推荐系统将面临算法的扩展性问题。一类方法是采用并行技术,以提高算法的运行效率^[32-34]。比如,文献[32]提出了一种基于扩展向量的并行协同过滤推荐模型,为了解决冷启动问题和向目标用户提供更准确的推荐结果,文中对项目向量进行了扩展,并运用并行计算框架对系统进行了进一步的优化。与传统的协同过滤推荐方法相比,该方法不仅克服了冷启动问题,提高了一倍的推荐精度,而且在理想环境下可以提高170倍运行速度。

另一类方法是采用降维、聚类、分类等策略对评分样本数据进行离线学习,建立可以用来推荐的模型,一定程度上解决了算法的扩展性问题。例如,SVD^[14, 17-18]等降维技术通过压缩矩阵,降低算法的时间复杂度,同时确保推荐结果的准确性。文献[35]和[36]为了解决算法的扩展性问题,在原有的协同过滤推荐方法中融入了聚类技术,以减少邻居计算时项目或用户上的查询空间。

基于模型的协同过滤算法是解决扩展性问题的有效途径,国内外出现了大量的研究成果,也出现了基于不同数据挖掘技术、机器学习方法对应的建模算法。比如,降低维度的PCA方法^[37-38]、矩阵分解方法^[14, 17-22, 39-40];分类技术的人工神经网络^[29, 31, 41]、贝叶斯分类^[11, 42]和决策树方法^[39, 43-44];聚类技术的K-means、DBScan、Spectral Clustering(谱聚类)方法^[24, 35-36],以及基于Apriori、FP-Tree、PrefixSpan算法的关联规则方法^[45-46]。

以上方法,既可以单独使用,也可以混合使用(文献[39]既使用了矩阵分解又使用了决策树),尤其矩阵分解技术能够大幅度降低原评分数据的维度,是目前比较好的解决数据稀疏和扩展性问题的方法。分类技术和聚类方法一定程度上减少邻居查询的空间,提高算法的运行效率。关联规则技术从购物篮中挖掘商品频繁共现的先验规则,并根据这个规则缩小候选商品的数量,同样提高了算法的效率。

4 协同过滤推荐算法的研究热点

4.1 融合大数据处理技术

随着时间的推移,系统中用户和项目的数量不断增加,而他们之间的关联数据也在不断的增长。数以亿计的海量数据给数据的存储和计算处理带来了极大的挑战。虽然,矩阵分解技术能够降低算法的时间和空间复杂度,易于编程实现,预测精度较高以及非常好的扩展性,但是,该方法一方面丢失了原评价数据的信息,另一方面推荐的结果不具有很好的可解释性(因为低秩特征矩阵很难用实际意义的概念来解释)。

为了解决以上问题,国内外的学者致力于算法的并行化研究。虽然针对大数据环境下分布式算法的研究起步不久,但已经被成功地引入到推荐算法的并行处理,必将给推荐算法带来新的发展机遇,并且成为推荐算法研究中的一个新的热点方向。

文献[21]使用Apache Spark实现基于用户的协同过滤推荐算法的并行化处理,在算法中融合降维技术、聚类技术以解决数据稀疏问题和算法扩展性问题,同时为了缓解冷启动问题他们还试图引入项目的标签特征。文献[33]基于分布式工作原理,将协同过滤推荐算法有效引入到Hadoop平台,实验结果表明,该方法能有效提高算法的响应时间,但也存在着数据稀疏极其稀疏

情况下推荐精度较低的不足。文献[47]为了解决算法扩展性问题,提出了基于 MapReduce 并行计算与项目分类的协同过滤算法,实验证明该方法确实高效。文献[48]针对基于项目协同过滤算法在 MapReduce 下存在多个作业之间严重的磁盘读写冗余及资源申请操作重复的不足,将该算法移植到迭代计算及内存计算均具有优势的 Spark 平台,实验结果表明,算法在后者运行时间和效率等性能上均比前者有所提升。

目前,公认的大数据平台有 Apache 的 Hadoop 和 Spark,前者提供的 MapReduce 是一种分布式计算框架,能够解决单机无法解决的大数据处理问题,但对于多个并行操作之间重用数据集表现不佳,而后者作为 Hadoop 的一种补充,在处理迭代工作与交互式数据分析方面更胜一筹。推荐算法的应用场景面临着数据量大、数据结构相对复杂的情况,因此,将其移植到大数据并行平台将成为一种必然。

4.2 融合社会网络分析技术

用户对项目的评分数据是协同过滤推荐算法的关键数据来源,但是,很多用户对自己不感兴趣的产品都采取不评分或者随意评价的态度,这就导致获得用户真实的兴趣比较困难。另外,如果评分信息不真实(如恶意评分)将会大大影响算法的推荐精度,结合社会网络环境中信任度观念可以有效地解决虚假评分或恶意评分给推荐系统带来的负面影响。美国著名的第三方调查机构尼尔森进行了有关用户对推荐因素的调查^[49],调查结果表明,90%的用户相信朋友的推荐,70%的用户相信网上其他用户的评价(这些用户很有可能互不认识)。由此可见,好友的推荐对于增加用户对推荐结果的信任度非常重要。针对社会网络分析技术融合到协同过滤推荐算法中可以提高推荐的质量问题,也将成为推荐算法研究中的一个新的热点方向。

文献[49]和[50]研究表明,相比推荐系统的推荐,人们更偏爱朋友的推荐,人们之间的信任度和兴趣相似度具有正相关,从而证明了社会网络分析技术是可以用来改善推荐效果的。文献[51]研究了用户的社会背景对推荐结果的影响,实验证明推荐过程中用户更倾向于来自熟人的推荐。文献[52]提出了一种新的用户相似度计算方法,它利用社会网络分析技术挖掘出用户间的关系,并把这种关系映射为信任度来填补用户评价数据,从而解决数据稀疏性问题。文献[53]利用协同过滤算法和信任传播理论得到一个团队推荐模型。他们从真实的社会网络 scholar@t(<http://www.scholat.com>)获取数据并进行实验,实验结果表明他们提出的团队推荐方法是有效的。文献[54]在传统的基于用户聚类的协同过滤算法基础上,融入了社会网络中的关键用户,实验结果表明这些关键用户的加入可以提高协同过滤算法的推荐准确性,同时证明社会网络中用户兴趣与关键用户

的兴趣是相关的。文献[55]提出一种将用户信任和矩阵分解相结合的社会化推荐方法。实验结果表明,该数据稀疏性和恶意评分行为问题可以得到缓解,并可以得到更高的预测精度。

社交网络时代,通过社交网络发现用户信任的好友集合,并在此基础上建立信任网络,相比传统协同过滤推荐方法通过历史数据找到的好友更多,推荐结果更具说服力。因此,社会网络分析技术在研究领域获得了广泛关注,将其研究成果应用到推荐系统中是一个值得探索的话题。

4.3 融合关键用户分析技术

在真实的推荐系统中,往往存在着一些具有较高交易经验和评分客观性高的关键用户,他们在推荐过程中起着非常重要的作用。研究表明基于少部分关键用户的推荐更能取得好的推荐效果,对于改善推荐系统的效率和准确率都具有积极的意义。文献[56]实验证明,关键用户的数量大概占有所有用户的20%,而使用这20%用户的数据计算其他用户的推荐列表,可以达到使用所有用户90%的准确率。

文献[18]首先使用奇异值分解对评分数据进行降维操作,为后期的项目聚类做好准备,然后使用 K-means 算法定义专家用户所在的领域并根据目标用户动态产生专家用户。实验表明,这种基于专家思想的音乐推荐系统具有较好的实时性和准确性。文献[57]提出了一种综合用户特征及专家信任的协同过滤推荐算法,该算法融合了用户的特征数据,降低了数据集的稀疏性,而且将目标用户的邻居限制在专家集合中。实验结果表明,改进的算法能够有效缓解冷启动问题,并且提高了推荐精度。

发展至今,针对推荐系统中用户重要性的研究相对较少,而实际应用中,那些被称之为“专家”的用户往往对其他用户的建议非常重要。用户重要性研究可以识别出系统中真正的关键用户,并能区分开那些恶意评分的用户,对于改善推荐系统的效率和健壮性具有重要的意义。如何挖掘这些潜在的“专家”,并发挥他们在推荐过程中的作用是一个新兴的课题。

5 总结

目前,协同过滤推荐技术在数据稀疏性、冷启动问题和扩展性方面面临着一定的挑战。国内外学者提出了各种解决方案,比如矩阵分解方法既可以解决数据稀疏性问题,也可以解决算法扩展性问题。向算法中融入用户的人口统计学信息、背景知识和信任关系可以缓解协同过滤技术的冷启动问题。另外,新的社会网络分析技术、大数据的并行技术,以及结合关键用户分析技术给其带来了新的契机,而如何利用这些技术提高系统的推荐精度和效率将会成为新的研究热点。

本文介绍了协同过滤推荐算法基本概念、协同过滤推荐算法的算法流程,以及算法性能评估指标;列举了该算法所面临的三大问题,并分别讨论了这三个问题的解决方案以及国内外学者的研究现状;最后提出了该算法近几年的研究新热点。

参考文献:

- [1] Isinkaye F O, Folajimi Y O, Ojokoh B A. Recommendation systems: Principles, methods and evaluation[J]. Egyptian Informatics Journal, 2015, 16(3): 261-273.
- [2] 项亮. 推荐系统实践[M]. 北京: 人民邮电出版社, 2012: 44-53.
- [3] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms[C]//Proceedings of the 10th International Conference on World Wide Web, 2001: 285-295.
- [4] Recommendation algorithm and code implementation based on collaborative filtering[EB/OL]. (2015-05-08) [2017-09-15]. http://mp.weixin.qq.com/s?__biz=MzA3MDg0MjgxNQ==&mid=204823185&idx=1&sn=0fae41b43dbd9e8a8e67ca0aced393ae&3rd=MzA3MDU4NTYzMw==&scene=6#rd.
- [5] Adomavicius G, Tuzhilin A. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions[J]. IEEE Transactions on Knowledge and Data Engineering, 2005, 17(6): 734-749.
- [6] Schafer J B, Konstan J, Riedl J. Recommender systems in E-commerce[C]//Proceedings of ACM Conference on Electronic Commerce, 1999: 158-166.
- [7] Lee W P, Ma C Y. Enhancing collaborative recommendation performance by combining user preference and trust-distrust propagation in social networks[J]. Knowledge-Based Systems, 2016, 106(1): 125-134.
- [8] 孙金刚, 艾丽蓉. 基于项目属性和云填充的协同过滤推荐算法[J]. 计算机应用, 2012, 32(3): 658-660.
- [9] 黄裕洋, 金远平. 一种综合用户和项目因素的协同过滤推荐算法[J]. 东南大学学报: 自然科学版, 2010, 40(5): 917-921.
- [10] Di Jiaqi, Wang Nihong. Incremental collaborative filtering algorithm based on GridGIS[J]. Computer Science, 2013, 40(12): 219-222.
- [11] 郭彩云, 王会进. 改进的基于标签的协同过滤算法[J]. 计算机工程与应用, 2016, 52(8): 56-61.
- [12] Xu Y, Yin J. Collaborative recommendation with user generated content[J]. Engineering Applications of Artificial Intelligence, 2015, 45(1): 281-294.
- [13] Cui H, Zhu M. Collaboration filtering recommendation optimization with user implicit feedback[J]. Journal of Computational Information Systems, 2014, 10(14): 5855-5862.
- [14] Sarwar B, Karypis G, Konstan J, et al. Application of dimensionality reduction in recommender systems—A case study[C]//Proc of the WebKDD 2000 Workshop at the ACM-SIGKDD Conf on Knowledge Discovery in Databases (KDD 2000), 2000: 1-12.
- [15] Samatthiyadikun P, Takasu A, Maneeroj S. Multicriteria collaborative filtering by Bayesian model-based user profiling[J]. Information Reuse and Integration (IRI), 2012, 59(5): 124-131.
- [16] 高风荣, 杜小勇, 王珊. 一种基于稀疏矩阵划分的个性化推荐算法[J]. 微电子学与计算机, 2004, 21(2): 58-62.
- [17] Zhou X, He J, Huang G, et al. SVD-based incremental approaches for recommender systems[J]. Journal of Computer and System, 2015, 81(4): 717-733.
- [18] Lee K, Lee K. Using dynamically promoted experts for music recommendation[J]. IEEE Transactions on Multimedia, 2014, 16(5): 1201-1210.
- [19] Funk S. Netflix update: Try this at home[EB/OL]. [2017-09-15]. <http://sifter.org/~simon/journal/20061211.html>.
- [20] Koren Y. Factorization meets the neighborhood: a multifaceted collaborative filtering model[C]//Proceedings of International Conference on Knowledge Discovery and Data Mining, 2008: 426-434.
- [21] Salakhutdinov R, Mnih A. Probabilistic matrix factorization[C]//Advances in Neural Information Processing Systems, 2007: 1257-1264.
- [22] Salakhutdinov R, Mnih A. Bayesian probabilistic matrix factorization using Markov chain Monte carlo[C]//Proceeding of the 25th International Conference on Machine Learning, 2008: 880-887.
- [23] Pereira A L V, Hruschka E R. Simultaneous co-clustering and learning to address the cold start problem in recommender systems[J]. Knowledge-Based Systems, 2015, 82: 11-19.
- [24] Ba Q, Li X, Bai Z. Clustering collaborative filtering recommendation system based on SVD algorithm[C]//Proceedings of IEEE International Conference on Software Engineering & Service Science, 2013: 963-967.
- [25] He J, Chu W. A Social Network-based Recommender System (SNSR)[M]. [S.l.]: Springer US, 2010: 47-74.
- [26] Shambour Q, Lu J. An effective recommender system by unifying user and item trust information for B2B applications[J]. Journal of Computer and System Sciences, 2015, 81(7): 1110-1126.
- [27] Balabanovic M, Shoham Y. Fab: content-based collaborative recommendation[J]. Communications of the ACM, 1997, 40(3): 66-72.
- [28] Ahn H J. A new similarity for collaborative filtering to alleviate the new user cold-starting problem[J]. Information Science, 2008, 178(1): 37-51.
- [29] Bobadilla J, Ortega F, Hernando A, et al. A collaborative

- filtering mitigate the new user cold start problem[J]. Knowledge Based Systems, 2012, 26: 225-238.
- [30] Zhang F, Gong T, Lee V E, et al. Fast algorithms to evaluate collaborative filtering recommender systems[J]. Knowledge-Based Systems, 2016, 96: 96-103.
- [31] Yuan J, Shalaby W, Korayem M, et al. Solving cold-start problem in large-scale recommendation engines: A deep learning approach[C]//Proceedings of IEEE International Conference on Big Data, 2017: 1901-1910.
- [32] Su H, Zhu Y, Wang C, et al. Parallel collaborative filtering recommendation model based on expand-vector[C]//Proceedings of the IEEE Second International Conference on Cognitive Systems and Information Processing, Beijing, China, 2014: 102-113.
- [33] 田保军, 胡培培, 杜晓娟, 等. Hadoop下基于聚类协同过滤推荐算法优化的研究[J]. 计算机工程与科学, 2016, 38(8): 1615-1624.
- [34] Panigrahi S, KLenka R, Stitipragyan A. A hybrid distributed collaborative filtering recommender engine using apache spark[J]. Procedia Computer Science, 2016, 83(1): 1000-1006.
- [35] Liao C L, Lee S J. A clustering based approach to improving the efficiency of collaborative filtering recommendation[J]. Electronic Commerce Research & Applications, 2016, 18: 1-9.
- [36] Das J, Mukherjee P, Majumder S, et al. Clustering-based recommender system using principles of voting theory[C]//Proceedings of the International Conference on Contemporary Computing and Informatics, 2014: 230-235.
- [37] Li Yuanbo, Cao H. Collaborative filtering recommendation algorithm based on PCA dimension reduction[J]. Computer Technology & Development, 2016, 2: 26-30.
- [38] Yu X, Li M. Effective hybrid collaborative filtering model based on PCA-SOM[J]. Systems Engineering—Theory & Practice, 2010, 30(10): 1850-1854.
- [39] 高玉凯, 王新华, 郭磊, 等. 一种基于协同矩阵分解的用户冷启动推荐算法[J]. 计算机研究与发展, 2017, 54(8): 1813-1823.
- [40] 张航, 叶东毅. 一种基于多正则化参数的矩阵分解推荐算法[J]. 计算机工程与应用, 2017, 53(3): 74-79.
- [41] Wei J, He J, Chen K, et al. Collaborative filtering and deep learning based recommendation system for cold start items[J]. Expert Systems with Applications, 2017, 69: 29-39.
- [42] Samatthiyadikun P, Takasu A, Maneeroj S. Multicriteria collaborative filtering by Bayesian model-based user profiling[C]//Proceedings of IEEE International Conference on Information Reuse & Integration, 2012: 124-131.
- [43] 谢霖铨, 梁博群. 结合用户特征分类和动态时间的协同过滤推荐[J]. 计算机工程与应用, 2017, 53(6): 80-84.
- [44] Bouza A, Reif G, Bernstein A, et al. SemTree: Ontology-based decision tree algorithm for recommender systems[C]//Proceedings of International Semantic Web Conference, 2008.
- [45] 陈平华, 陈传瑜, 洪英汉. 一种结合关联规则的协同过滤推荐算法[J]. 小型微型计算机系统, 2016, 37(2): 287-292.
- [46] Ye H. A personalized collaborative filtering recommendation using association rules mining and self-organizing map[J]. Journal of Software, 2011, 6(4): 732-739.
- [47] 程曦, 陈军. 基于 MapReduce 与项目分类的协同过滤算法[J]. 计算机工程, 2016, 42(7): 194-198.
- [48] 廖彬, 张陶, 国冰磊, 等. 基于 Spark 的 ItemBased 推荐算法性能优化[J]. 计算机应用, 2017, 37(7): 1900-1905.
- [49] Global Advertising Consumers Trust Real Friends and Virtual Strangers the Most[EB/OL]. [2017-09-15]. <http://blog.nielsen.com/nielsenwire/consumer/global-advertising-consumers-trust-real-friends-and-virtual-strangers-the-most/>.
- [50] 张佩云, 黄波, 谢荣见, 等. 一种基于社会网络信任关系的服务推荐方法[J]. 小型微型计算机系统, 2014, 35(2): 222-227.
- [51] Bonhard P, Sasse M A. Knowing me, knowing you—Using profiles and social networking to improve recommender systems[J]. Bt Technology Journal, 2006, 24(3): 84-98.
- [52] Feng Y, Li J, Xu H, et al. Collaborative recommendation method improvement based on social network analysis[J]. Journal of Computer Applications, 2013, 33(3): 841-844.
- [53] Hong S, Mao C, Yang Z, et al. A new team recommendation model with applications in social network[C]//Proceedings of the 2014 IEEE 18th International Conference on Computer Supported Cooperative Work in Design, 2014: 644-648.
- [54] 张莉, 滕丕强, 秦桃. 利用社会网络关键用户改进协同过滤算法性能[J]. 情报杂志, 2014, 33(4): 196-200.
- [55] Li H, Hu Y, Shi J. Collaborative recommendation algorithm under social network circumstances[J]. Journal of Computer Applications, 2013, 33(11): 3067-3070.
- [56] Zeng W, Zeng A, Liu H, et al. Uncovering the information core in recommender systems[J]. Scientific Reports, 2014, 4(1): 6128-6140.
- [57] 高发展, 黄梦醒, 张婷婷. 综合用户特征及专家信任的协作过滤推荐算法[J]. 计算机科学, 2017, 44(2): 103-106.
- [58] Rendle S. Factorization machines[C]//Proceedings of 2010 IEEE 10th International Conference on Data Mining (ICDM), 2010: 995-1000.
- [59] 彭敏, 席俊杰, 代心媛, 等. 基于情感分析和 LDA 主题模型的协同过滤推荐算法[J]. 中文信息学报, 2017, 31(2): 194-203.